

TCC - Desenvolvimento de Solução

Desenvolvimento de uma Solução de Geração Aumentada por Recuperação (RAG) para Automatizar a Consulta de documentos normativos da UNIVASF

Development of a Retrieval-Augmented Generation (RAG) Solution to Automate the Querying of UNIVASF's Normative Documents

Bruno Matheus Pereira Silva [Discente Engenharia de Computação | bruno.matheuss@discente.univasf.edu.br]
Prof.(a) Dr.(a) Jadsonlee da Silva Sá [Orientador(a) - UNIVASF | jadsonlee.sa@univasf.edu.br]

FUNDAÇÃO UNIVERSIDADE FEDERAL DO VALE DO SÃO FRANCISCO (UNIVASF), Juazeiro-BA

Resumo. A complexidade e a fragmentação de documentos regulatórios universitários geram fricção administrativa e desamparo informacional, fatores que contribuem para a evasão no ensino superior. Este trabalho propõe o desenvolvimento de um assistente virtual baseado na arquitetura *Advanced RAG* (Retrieval-Augmented Generation) para consulta de documentos normativos da UNIVASF. A solução diferencia-se pela implementação de uma estratégia de *chunking* semântico-hierárquico fundamentada na Lei Complementar n.º 95/1998, que preserva a integridade lógica dos dispositivos legais, aliada a um *pipeline* de recuperação em dois estágios com refinamento via *Cross-Encoders*. A validação do protótipo utiliza o *framework LLM-as-a-Judge* (RAGAS) submetido a um protocolo de calibração humana, visando garantir rastreabilidade da fonte e mitigação severa de alucinações em domínios de alto risco.

Abstract. The complexity and fragmentation of university regulatory documents create administrative friction and informational helplessness, contributing to dropout rates in higher education. This work proposes the development of a virtual assistant based on the Advanced RAG (Retrieval-Augmented Generation) architecture for querying UNIVASF's normative documents. The solution distinguishes itself by implementing a semantic-hierarchical chunking strategy based on Complementary Law No. 95/1998, preserving the logical integrity of legal devices, combined with a two-stage retrieval pipeline featuring Cross-Encoder refinement. The prototype validation employs the LLM-as-a-Judge framework (RAGAS) under a human calibration protocol, aiming to ensure source traceability and severe mitigation of hallucinations in high-stakes domains.

Palavras-chave: Inteligência Artificial, Geração Aumentada por Recuperação (RAG), Modelos de Linguagem Grande (LLM), Sistemas de Resposta a Perguntas

Keywords: Artificial Intelligence, Retrieval-Augmented Generation (RAG), Large Language Models (LLM), Question Answering Systems

Recebido/Received: DD Month YYYY • Aceito/Accepted: DD Month YYYY • Publicado/Published: DD Month YYYY

1 Introdução

No Brasil, o cenário de interfaces conversacionais encontra-se em franca expansão. O mercado de *chatbots* alcançou USD 535,1 milhões em receita em 2024 e projeta-se que atinja USD 1.893,9 milhões até 2030, com uma taxa de crescimento anual composta de 23,4% [Grand View Research, 2024]. Esse crescimento é impulsionado não apenas por fatores econômicos, mas por uma característica cultural singular do país: a alta capilaridade de aplicativos de mensageria. Segundo o mapa do ecossistema brasileiro de *bots*, o Brasil consolidou-se como um dos líderes globais no uso de canais como WhatsApp para automação, moldando o comportamento do usuário final que passou a exigir disponibilidade imediata e onipresença no atendimento [Mobile Time and Opinion Box, 2024].

Contudo, essa expectativa de agilidade contrasta

severamente com a realidade administrativa das Instituições de Ensino Superior (IES). Dados recentes do Censo da Educação Superior revelam que o sistema brasileiro ultrapassou a marca histórica de 10 milhões de matrículas, impulsionado pela modalidade a distância (EaD), na qual o suporte presencial é escasso [INEP and Ministério da Educação, 2025]. O impacto da falta de amparo e da complexidade informacional reflete-se em indicadores críticos: para o coorte de alunos ingressantes em 2015, a taxa de desistência acumulada atingiu 60% em 2024 [INEP and Ministério da Educação, 2025].

Nesse contexto, alunos e servidores enfrentam dificuldades recorrentes ao consultar documentos institucionais extensos e hierarquicamente estruturados como estatutos, regimentos gerais e resoluções de conselhos universitários. Embora a literatura classifique a evasão como um fenômeno multifatorial (envolvendo aspectos socioeconômicos e vocacionais), estudos apontam que a

falta de integração acadêmica e o suporte institucional deficiente são determinantes clássicos para o abandono [Saccaro et al., 2019]. Esse cenário de desamparo informacional agravou-se no pós-pandemia, exigindo novas estratégias de mitigação baseadas em tecnologia [Santos et al., 2025]. O processo manual de busca torna-se, portanto, um gargalo que consome tempo e gera insegurança, contribuindo para a estatística de evasão por fricção administrativa.

Tecnicamente, os *Large Language Models* (LLMs), como GPT-4o e Llama-3, representam um avanço significativo em relação aos *chatbots* tradicionais baseados em árvores de decisão. Entretanto, quando utilizados isoladamente, estão sujeitos ao fenômeno da alucinação¹ [Ji et al., 2023]. Pesquisas recentes do laboratório de regulação de Stanford demonstram que LLMs genéricos alucinam em até 69% das respostas sobre jurisprudência e regulamentos, tornando-os inadequados para domínios de alto risco como o acadêmico [Dahl et al., 2024].

A arquitetura de *Retrieval-Augmented Generation* (RAG) mitiga esse problema ao combinar memória paramétrica (o conhecimento pré-treinado do LLM) com memória não-paramétrica (uma base de conhecimento externa vetorial), permitindo respostas fundamentadas em documentos reais e com citação explícita de fontes [Lewis et al., 2021; Gao et al., 2023]. Apesar dos avanços, a eficiência do RAG em textos jurídicos altamente estruturados depende criticamente da qualidade do pré-processamento e da estratégia de indexação (*chunking*)² [Liu et al., 2024].

O presente trabalho propõe o desenvolvimento de um protótipo *Advanced RAG* otimizado para consulta de estatutos e regulamentos universitários brasileiros. As principais contribuições incluem: estratégia de *chunking* semântico-hierárquico (baseada na estrutura de artigos de lei) enriquecida com metadados estruturais; implementação de *reranking*³ contextual para refinamento da recuperação de documentos; e proposta de avaliação quantitativa fundamentada no paradigma *LLM-as-a-Judge*. Diferentemente de métricas tradicionais baseadas em contagem de palavras, essa abordagem utiliza Modelos de Linguagem de grande porte como "juízes" para avaliar semanticamente a qualidade das respostas. A implementação utiliza o *framework* RAGAS (*Retrieval Augmented Generation Assessment*), que mensura a fidelidade factual e a relevância da resposta sem depender obrigatoriamente de referências humanas [Es et al., 2025]. A validação será conduzida sobre um *dataset* híbrido, combinando um volume massivo de pares pergunta-resposta gerados sinteticamente com um con-

junto de validação padrão-ouro curado manualmente, visando unir escalabilidade estatística com precisão humana.

O objetivo geral desta pesquisa é desenvolver e validar experimentalmente um protótipo de assistente virtual baseado em arquitetura RAG avançada, capaz de responder consultas sobre estatutos e regulamentos universitários com alta precisão, fidelidade à fonte e transparência. Especificamente, pretende-se: realizar o levantamento e pré-processamento (ETL)⁴ de documentos institucionais, implementando técnica de *chunking* baseada na estrutura de artigos de lei; implementar o *pipeline* RAG integrando recuperação vetorial e etapa de reordenação (*reranking*); desenvolver uma interface *web* conversacional que apresente as citações e links para os documentos originais consultados; e avaliar o desempenho do protótipo comparando-o a um *baseline* (*Naive RAG*) através das métricas de fidelidade e relevância do *framework* RAGAS.

Este trabalho está organizado da seguinte forma: a Seção 2 apresenta a Fundamentação Teórica sobre LLMs e RAG; a Seção 3 detalha a Metodologia e a arquitetura proposta; a Seção 4 discute os Trabalhos Relacionados e a diferenciação da solução; e a Seção 5 apresenta o Cronograma de execução para o TCC 2 e as considerações finais.

2 Fundamentação Teórica

Esta seção apresenta os conceitos fundamentais que sustentam a solução proposta, abordando desde a arquitetura básica de recuperação de informações até as estratégias avançadas de segmentação de texto e avaliação automatizada.

2.1 O Paradigma RAG: *Naive*, *Advanced* e *Modular*

Os Modelos de Linguagem Grande (LLMs) possuem um conhecimento paramétrico estático, limitado à data de corte do seu treinamento ($T_{cut-off}$)⁵. Para mitigar essa limitação em contextos dinâmicos ou proprietários, Lewis et al. [2021] introduziram a arquitetura de Geração Aumentada por Recuperação (RAG).

Conforme categorizado pelo levantamento abrangente de Gao et al. [2023], o paradigma evoluiu em três estágios arquiteturais, impulsionados pela necessidade de maior precisão e controle sobre a alucinação:

Naive RAG: Representa a implementação canônica seguindo o fluxo linear "Recuperar-Ler-Gerar". O sistema converte a consulta do usuário em vetores, busca os *top-k*⁶ documentos similares via distância

¹No contexto de LLMs, alucinação refere-se à geração confiante de informações factualmente incorretas ou sem base no contexto fornecido.

²*Chunking*: Processo de segmentação de textos longos em unidades menores (fragmentos) para viabilizar o processamento dentro da janela de contexto limitada dos modelos de linguagem.

³*Reranking*: Etapa de refinamento onde um modelo mais preciso (geralmente um *Cross-Encoder*) reavalia e reordena os documentos recuperados inicialmente para garantir que os mais relevantes fiquem no topo da lista.

⁴*Extract, Transform, Load* (Extração, Transformação e Carga): Processo de engenharia de dados que envolve a extração de dados brutos, limpeza/transformação e carregamento em base vetorial.

⁵ $T_{cut-off}$ (Data de Corte): Marco temporal que delimita o fim da coleta de dados para o pré-treinamento do modelo. Eventos, leis ou documentos publicados após esta data ($t > T_{cut-off}$) são desconhecidos pela memória interna do LLM, tornando mandatória a utilização de fontes externas para manter a factualidade.

⁶*Top-k*: Hiperparâmetro de recuperação que restringe o re-

de cosseno e os injeta no *prompt* do LLM. **Limitações:** Esta abordagem sofre com baixa precisão na recuperação (trazendo documentos irrelevantes que confundem o modelo) e baixa revocação (falhando em encontrar a resposta correta se a terminologia não for exata), resultando frequentemente em alucinações ou respostas desconectadas [Gao et al., 2023].

Advanced RAG: Desenvolvido para superar as falhas do *Naive RAG*, este paradigma introduz componentes de otimização em duas frentes:

1. **Pré-recuperação:** Refinamento da consulta do usuário (ex: *Query Rewriting*) para alinhar a busca semântica;
2. **Pós-recuperação:** Reordenação (*Reranking*) e filtragem dos documentos recuperados, garantindo que apenas contextos de alta densidade informacional cheguem ao LLM.

É a arquitetura predominante para domínios de alta complexidade, como o jurídico e o médico.

Modular RAG: Uma arquitetura mais flexível e orquestrada, que permite módulos independentes (como busca na *web*, calculadora, ou verificação de fatos) e ciclos iterativos, onde o LLM pode decidir "buscar novamente" caso julgue o contexto insuficiente.

Para o domínio de estatutos universitários, onde a precisão terminológica é crítica e a tolerância a erro é zero, o *Naive RAG* mostra-se insuficiente. Portanto, este trabalho adota a arquitetura **Advanced RAG**, focando especificamente na otimização da indexação (via *chunking* estrutural) e na pós-recuperação (via *reranking*).

2.2 Processamento de Dados e Estratégias de Indexação

A construção de uma base de conhecimento confiável para sistemas RAG exige um *pipeline* robusto de Engenharia de Dados. Conforme definem as melhores práticas de ETL (*Extract, Transform, Load*), a qualidade da informação recuperada é diretamente proporcional à qualidade do pré-processamento aplicado aos dados brutos não estruturados [Seenivasan, 2023].


No contexto de estatutos universitários, originalmente disponibilizados em formato PDF, a etapa de transformação é crítica. Ela envolve não apenas a extração textual, mas a higienização dos dados (remoção de cabeçalhos repetitivos, números de página e ruído de formatação) para maximizar a integridade semântica antes da indexação.

2.2.1 O Desafio do Contexto: Fenômeno "Lost in the Middle"

Após o ETL, a eficácia do sistema recai sobre a estratégia de segmentação (*chunking*). Este processo apresenta desafios críticos em janelas de contexto extensas. Liu et al. [2024] demonstram que a performance dos LLMs

sultado da busca aos k documentos com maior pontuação de similaridade vetorial em relação à consulta do usuário, descartando os demais.

Figura 1. Comparação entre o fluxo Naive RAG (esquerda) e Advanced RAG com etapas de Query Rewriting e Reranking (direita).



Fonte: Adaptado de Gao et al. (2023)

não é uniforme ao longo do *prompt*: os modelos sofrem de um viés de posição em forma de "U", apresentando alta precisão no início (primazia) e no fim (recência), mas degradando significativamente a recuperação de informações posicionadas no meio da sequência.

Portanto, uma estratégia de *chunking* ineficaz não apenas fragmenta o texto, mas corre o risco de posicionar trechos cruciais como parágrafos de exceção em uma lei justamente na "zona cega" do mecanismo de atenção do modelo.

Portanto, a estratégia de *chunking* não é apenas uma questão de divisão de caracteres, mas de otimização da janela de atenção do modelo para evitar a diluição do contexto relevante.

2.2.2 Chunking Semântico-Hierárquico em Textos Normativos

Em textos jurídicos, a segmentação ingênua por tamanho fixo (ex: 512 *tokens*⁷ com sobreposição) costuma romper a unidade semântica dos dispositivos legais, separando o *caput* (enunciado principal) de seus parágrafos, incisos e alíneas. Essa fragmentação arbitrária reduz drasticamente o *Context Recall*⁸, pois o modelo perde a relação de dependência entre a regra geral e suas exceções [Guha et al., 2023].

Para mitigar esse problema e o fenômeno *Lost in the Middle*, este trabalho propõe uma estratégia semân-

⁷ *Token*: Unidade atômica de processamento de texto em LLMs. Um *token* pode representar uma palavra inteira, uma sílaba ou um caractere, dependendo do tokenizador utilizado (ex: 1000 tokens $\approx$ 750 palavras em inglês).

⁸ *Context Recall* (Revocação de Contexto): Métrica que avalia se a informação recuperada pelo sistema contém todos os elementos necessários da "verdade fundamental" (*Ground Truth*) para responder corretamente à pergunta, medindo a capacidade do sistema de não "perder" dados relevantes.

Figura 2. Pipeline de Engenharia de Dados e Indexação. O fluxo inicia com a extração de dados brutos (PDFs), seguido pelo tratamento de ruídos (ETL), segmentação semântica (*Chunking*), vetorização (*Embedding*) e persistência na base vetorial (Vector DB).



Fonte: Elaborado pelo autor (2025).

tica que respeita fronteiras naturais. No contexto nacional, a Lei Complementar n.º 95/1998 [Brasil, 1998] estabelece uma estrutura rígida e padronizada para atos normativos (Artigos, Parágrafos, Incisos), possibilitando a extração algorítmica de delimitadores.

Ao adotar um *chunking* orientado a dispositivos legais, garante-se que cada vetor na base de dados corresponda a uma unidade jurídica completa e autocontida, preservando a coerência normativa necessária para a recuperação [Dahl et al., 2024].

2.3 Otimização de Recuperação (Advanced RAG)

A recuperação vetorial tradicional utiliza arquiteturas do tipo *Bi-Encoder*, onde a consulta e os documentos são vetorizados independentemente no mesmo espaço latente. A similaridade é calculada via produto escalar ou cosseno. Embora eficiente computacionalmente para grandes bases (escala de milissegundos), essa abordagem comprime toda a informação semântica em um único vetor, resultando em perda de nuances sintáticas e relacionais, fenômeno conhecido como "gargalo de compressão semântica" [Reimers and Gurevych, 2019].

Em domínios regulatórios, onde a interpretação correta depende de preposições e condicionais estritas, a literatura aponta a necessidade de arquiteturas de recuperação em múltiplos estágios ou com refinamento semântico. As principais técnicas descritas no estado da arte incluem:

HyDE (*Hypothetical Document Embeddings*):

Proposta por Gao et al. [Gao et al., 2023], esta técnica atua como uma ponte semântica entre a intenção do usuário e o vocabulário formal dos documentos.

O funcionamento baseia-se na premissa de que é mais fácil para um vetor encontrar outro texto se-

melhante do que encontrar uma pergunta. O processo ocorre em dois passos:

1. O LLM alucina intencionalmente uma "resposta ideal" para a pergunta do usuário (ex: se o aluno pergunta "como trancar?", o modelo gera um texto contendo "procedimentos de trancamento de matrícula").
2. O sistema vetoriza essa resposta hipotética para buscar os documentos reais, superando o descompasso vocabular entre a dúvida informal e o texto normativo.

Query Expansion e Multi-Query: Frequentemente, uma única pergunta não contém termos suficientes para recuperar todo o contexto necessário. Esta técnica utiliza um LLM para decompor a consulta original em múltiplas variações (paráfrases) ou sub-perguntas, cobrindo diferentes ângulos do espaço vetorial.

Ao buscar por "direitos do aluno", por exemplo, o sistema pode expandir a busca para incluir termos correlatos como "prerrogativas discentes" e "assistência estudantil", aumentando significativamente a revocação (*recall*).

Reranking (Reordenação via *Cross-Encoder*):

Considerada o estado da arte para precisão, esta técnica atua como um "segundo olhar" criterioso sobre os documentos recuperados.

Enquanto a busca inicial (*Bi-Encoder*) prioriza a velocidade ao comparar vetores pré-calculados de forma independente, o *Cross-Encoder* processa a pergunta e o documento simultaneamente. A arquitetura concatena o par Pergunta (*Q*) e Documento (*D*) em uma única entrada para a rede neural *Transformer*, permitindo que o mecanismo de *Self-Attention* analise a interação profunda entre cada palavra da pergunta e cada palavra do documento.

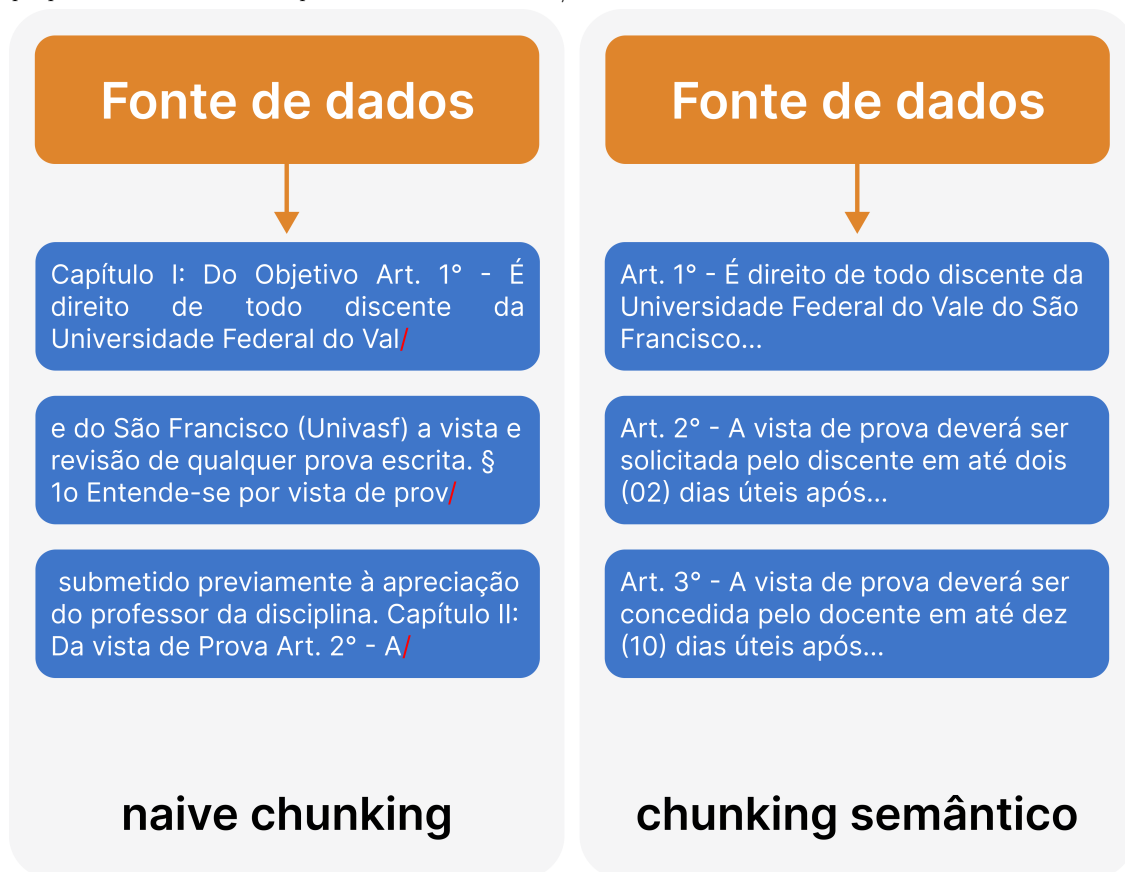
Embora computacionalmente mais custosa, essa abordagem captura nuances sintáticas finas (como a diferença entre "o aluno processa a universidade" e "a universidade processa o aluno") que modelos vetoriais simples tendem a perder. *Benchmarks* demonstram que essa reordenação pode elevar a métrica NDCG@10⁹ em mais de 10 pontos percentuais [Cohere, 2024].

2.4 Métricas de Avaliação: O Paradigma LLM-as-a-Judge

A avaliação de sistemas de geração de texto historicamente dependeu de métricas tradicionais focadas na correspondência exata de palavras, como BLEU e ROUGE. Entretanto, Li et al. [Li et al., 2024] argumentam em seu levantamento que tais métricas correlacionam-se fracamente com a qualidade semântica


⁹NDCG (*Normalized Discounted Cumulative Gain*): Métrica que avalia a qualidade da ordenação. Diferente da precisão simples, ela penaliza documentos relevantes que aparecem em posições baixas no *ranking*, valorizando sistemas que entregam a resposta correta nas primeiras posições (ex: Top-10).

Figura 3. Comparação entre chunking ingênuo (esquerda), que secciona artigos arbitrariamente, e chunking semântico-hierárquico (direita), que preserva a unidade do dispositivo conforme a LC 95/1998.



Fonte: Elaborado pelo autor (2025).

Figura 4. Arquitetura teórica de Recuperação em Dois Estágios (Funil). O primeiro estágio prioriza a revocação (Bi-Encoders), enquanto o segundo prioriza a precisão semântica (Cross-Encoders).



Fonte: Elaborado pelo autor (2025).

em tarefas de resposta a perguntas (QA), pois falham em capturar paráfrases ou respostas corretas que utilizam vocabulário distinto da referência.

Para superar a necessidade custosa de avaliação humana, consolidou-se o paradigma *LLM-as-a-Judge*, onde modelos de linguagem de grande porte (como GPT-4 ou Llama-3-70B) são empregados para avaliar a qualidade das saídas de outros modelos.

A confiabilidade dessa abordagem foi corroborada por Muhamed [2025] com a introdução do *framework*

CCRS¹⁰. O estudo demonstrou que, ao utilizar critérios estruturados de avaliação (como Clareza, Correção e Relevância) configurados em regime *zero-shot*¹¹, os juízes sintéticos conseguem atingir uma correlação de *Pearson*¹² superior a 0,8 com especialistas humanos. Esse resultado valida estatisticamente a substituição parcial da curadoria humana em etapas de validação em larga escala.

Dentre as metodologias propostas, o *framework* RAGAS (*Retrieval Augmented Generation Assessment*) destaca-se por introduzir métricas "sem referência", avaliando o sistema através da triangulação entre Pergunta, Contexto e Resposta [Es et al., 2025]:

Faithfulness (Fidelidade): Avalia a consistência factual.

O algoritmo decompõe a resposta em "afirmações atômicas" e verifica se cada proposição pode ser logicamente deduzida do contexto recuperado, pena-

¹⁰CCRS: Acrônimo para *Clarity, Correctness, Relevance, and Safety* (Clareza, Correção, Relevância e Segurança).

¹¹*Zero-shot*: Configuração onde o modelo executa a tarefa apenas com base nas instruções do *prompt*, sem receber exemplos prévios de treinamento.

¹²Coefficiente de Correlação de *Pearson* (r): Medida estatística que avalia a intensidade da relação linear entre dois conjuntos de dados. O valor varia de -1 a +1; na literatura psicométrica, um $r > 0,7$ é considerado uma correlação positiva forte, indicando alta concordância entre os avaliadores.

lizando informações alucinadas que não constam na fonte.

Answer Relevance (Relevância): Mede se a resposta endereça a intenção do usuário. Uma técnica comum envolve a geração reversa de perguntas a partir da resposta dada e o cálculo da similaridade semântica com a pergunta original.

Context Precision e Recall: Métricas focadas no recuperador. A precisão verifica a densidade de informações úteis no topo do ranking (evitando ruído), enquanto o *recall* mede se a totalidade da informação necessária para a resposta estava presente nos documentos recuperados.

Essa abordagem desacoplada permite diagnosticar se uma falha no sistema RAG originou-se na etapa de recuperação (falta de dados) ou na etapa de geração (falha de raciocínio).

Figura 5. A Triáde de Avaliação em sistemas RAG. As arestas do triângulo representam as métricas que governam as relações semânticas entre a Pergunta (*Query*), o Contexto recuperado e a Resposta gerada (*Answer*), conforme modelado pela literatura de *LLM-as-a-Judge*.



Fonte: Elaborado pelo autor (2025).

3 Metodologia

Esta pesquisa classifica-se como aplicada e exploratória, adotando a abordagem de *Design Science Research* (DSR) para a construção de um artefato computacional (o assistente virtual). O desenvolvimento do protótipo seguirá um *pipeline* de cinco etapas sequenciais, detalhadas a seguir.

3.1 Etapa 1: Coleta, Curadoria e Pipeline de ETL

A construção da Base de Conhecimento partirá de uma curadoria manual das normas vigentes na UNIVASF, organizadas taxonomicamente em uma estrutura de diretórios hierárquica (Figura 6). Essa organização prévia é fundamental, pois permite a injeção automática de metadados de categoria baseados no caminho do arquivo.

O *pipeline* de ETL projeta-se para utilizar técnicas de conversão baseadas em modelos de *layout* profundo. O processo divide-se em três subetapas:

- 1. Ingestão e Conversão Estruturada (*Docling*):** A extração textual utilizará a biblioteca de código aberto (*open-source*) **Docling** [IBM Research, 2024]. Diferentemente de extratores lineares (como PyMuPDF), o Docling aplica modelos de visão computacional para converter PDFs inclusive arquivos digitalizados via reconhecimento óptico de caracteres (OCR)¹³ em formato **Markdown** estruturado. Isso garante que tabelas, cabeçalhos e hierarquias visuais sejam preservados semanticamente antes mesmo da segmentação.
- 2. Transformação (Sanitização e Vigência):** Sobre o texto estruturado, serão aplicados filtros de limpeza e o módulo crítico de **Deteção de Revogação**:
 - O algoritmo rastreará padrões linguísticos de alteração normativa (ex: "Fica revogado o Art. X", "Vigência a partir de...");
 - Artigos identificados como revogados receberão a tag de metadado **status: revogado**, permitindo que o sistema RAG os filtre, garantindo segurança jurídica.
- 3. Padronização (Output):** O resultado final será um objeto JSON¹⁴ contendo o conteúdo em *Markdown* limpo, os metadados de origem e o status de vigência, servindo de insumo ideal para o *chunking* hierárquico.

3.2 Etapa 2: Indexação com *Chunking* Semântico-Hierárquico

A eficácia da recuperação depende diretamente da granularidade da informação. Aproveitando a estrutura em *Markdown* gerada pelo *Docling* na etapa anterior, este trabalho propõe a implementação de um algoritmo de *chunking* híbrido (Estrutural + Baseado em Regras). O processo segue três diretrizes:


1. Análise Sintática (*Parsing*) Semântica sobre *Markdown*:

O algoritmo iterará sobre os blocos de texto estruturado. Como o *layout* será resolvido na Etapa 1, as

¹³OCR (*Optical Character Recognition*): Tecnologia que converte imagens de texto (como páginas digitalizadas) em texto editável e pesquisável por máquina.

¹⁴JSON (*JavaScript Object Notation*): Formato leve de intercâmbio de dados independente de linguagem, legível por humanos e fácil de ser interpretado por máquinas, amplamente utilizado para transmitir dados estruturados em aplicações *web*.

Figura 6. Taxonomia da Base de Conhecimento. A estrutura de diretórios segregava documentos por tipologia, facilitando a injeção de metadados antes do processamento via Docling.



Fonte: Elaborado pelo autor (2025).

Expressões Regulares (RegEx) atuarão com alta precisão para classificar a tipologia jurídica dos blocos:

- *Caput* de Artigo: $(\backslash-?[A-Z])?\backslash.?$
 $r"\backslashs*(\backslash*\backslash\#)?\backslashs*Art\backslash.\backslashs\d+$
 $(\backslash-?[A-Z])?\backslash.?"$ (Identifica artigos...);
- Parágrafos: $r"\backslashs*(\backslash\backslashs\d+^\circ|Parágrafo\backslashs+único)"$;
- Incisos: $r"\backslashs*[IVXLCDM]+\backslashs-"$ (Captura numerais...).

2. Agrupamento Lógico:

A unidade mínima de indexação será o dispositivo legal completo. Aplica-se a regra de concatenação onde $Chunk_i = Caput + \sum(Paragrafos, Incisos)$. Isso evita a orfandade semântica, garantindo que exceções (parágrafos) nunca sejam separadas da regra geral (*caput*).

3. Política de Overflow e Recursividade:

Para mitigar o problema de artigos excessivamente longos (ex: Art. 12 com dezenas de incisos) que excedam a janela de contexto do modelo de *embedding*, implementa-se um mecanismo de **Recursividade *Fall-back***.

Algoritmo: Se o $len(Chunk_i) > Limit$ (ex: 2048 *tokens*), o sistema quebra o agrupamento e indexa os parágrafos individualmente. Crucialmente, cada parágrafo "filho" herda uma cópia do texto do "pai" (*caput*) como prefixo de contexto, mantendo a inteligibilidade vetorial.

Cada fragmento resultante será serializado em um objeto JSON enriquecido com metadados topológicos (Hierarquia: "Título II > Cap. I"), conforme ilustrado na Figura 7, antes de ser submetido ao modelo *text-embedding-3-large* OpenAI [2024a].

Figura 7. Exemplo da estrutura de dados (JSON) de um *chunk* processado. Note a preservação do agrupamento (Artigo + Parágrafos) no campo *content* e os metadados ricos para filtragem.

```

{
  "chunk_id": "estatuto_univasf_art_12",
  "content": "Art. 12. O corpo discente é constituído por...
    § 1º Entende-se por estudante regular...
    § 2º O estudante especial é aquele...",
  "metadata": {
    "source": "Estatuto da UNIVASF.pdf",
    "category": "Estatuto",
    "hierarchy": ["Título II", "Capítulo I"],
    "status": "vigente",
    "page_num": 14,
    "bbox": [100, 200, 500, 600] // Coordenada para highlight
  }
}

```

Fonte: Elaborado pelo autor (2025).

3.3 Etapa 3: Pipeline de Recuperação Otimizada (Funil)

O sistema de recuperação operará em uma arquitetura de **Filtragem em Três Estágios** para garantir que a resposta seja não apenas semanticamente próxima, mas juridicamente válida:

1. **Pré-Filtragem de Metadados (*Hard Filtering*):** Antes da busca vetorial, aplicar-se-á um filtro nos metadados estruturados gerados na Etapa 2. O sistema excluirá documentos marcados com *status: revogado*, garantindo que o espaço de busca considere apenas normas vigentes.
2. **Busca Densa (Recuperação):** Utilizando o algoritmo HNSW (*Hierarchical Navigable Small World*)¹⁵ implementado no ChromaDB, o sistema recuperará os 50 fragmentos (*top-k=50*) mais próximos da consulta no espaço vetorial. Esta etapa prioriza a revocação (*recall*), capturando um espectro amplo de candidatos potenciais.
3. **Reranking e Corte (Refinamento):** Os 50 candidatos serão reprocessados pelo modelo *Cross-Encoder Cohere Rerank-v3-multilingual* [Cohere, 2024]. Diferente do cosseno simples, este modelo avalia a interação profunda entre pergunta e documento. Nesta fase, aplica-se um limiar de corte (*thresholding*): apenas documentos com pontuação de relevância $\sigma > 0.4$ (em uma escala de 0 a 1) serão

¹⁵HNSW: Algoritmo de indexação vetorial aproximada baseado em grafos, que permite buscas extremamente rápidas (logarítmicas) em grandes bases de dados, sacrificando minimamente a precisão.

mantidos, até o limite de 5 fragmentos ($top-k=5$). Isso impede que o sistema injete ruído no contexto caso nenhum documento seja relevante.

3.4 Etapa 4: Engenharia de Prompt e Interface Auditável

A camada de síntese foi desenhada para garantir estrita aderência factual, implementando técnicas de engenharia de *prompt* recomendadas para tarefas de Perguntas e Respostas (QA) em domínios fechados [OpenAI, 2024b].

1. Configuração do Motor de Geração (Generative Engine):

Será utilizado o modelo GPT-4o configurado com amostragem determinística ($\tau = 0.0$), eliminando a aleatoriedade estocástica para priorizar a consistência. O modelo operará sob um sistema de *Prompt* rígido, estruturado para impor restrições de *Grounding*¹⁶ e *Negative Constraints*¹⁷. O Quadro 8 apresenta a instrução exata planejada.

Figura 8. System Prompt proposto para garantir o *Grounding*. A estrutura delimita claramente onde termina a instrução e onde começa o contexto injetado.

System Prompt:

Sua função é responder dúvidas de alunos baseando-se EXCLUSIVAMENTE no contexto fornecido abaixo (trechos de estatutos e resoluções). Você é um Assistente Jurídico da UNIVASF.

Sua função é responder dúvidas de alunos baseando-se EXCLUSIVAMENTE no contexto fornecido abaixo (trechos de estatutos e resoluções).

Diretrizes de Resposta:

1. CITAÇÃO OBRIGATÓRIA: Toda afirmação deve vir acompanhada da fonte (ex: "Conforme o Art. 15 da Resolução 10/2022...").

2. NEGATIVE CONSTRAINT: Se a resposta não estiver no contexto, responda apenas: "A informação solicitada não consta nos documentos consultados." Jamais invente ou use conhecimento externo.

3. TOM: Formal, direto e impessoal.

CONTEXTO RECUPERADO (Vigente):

{contexto_do_reranker}

PERGUNTA DO USUÁRIO:

{pergunta_usuario}

2. Interface e Transparência Algorítmica:

A interface final, a ser desenvolvida utilizando a biblioteca *ReactJS* para a camada de *frontend web*, implementará o conceito de **Auditabilidade Visual**. Diferente de *chatbots* convencionais, cada resposta será acompanhada por "Cartões de Evidência" (*Evidence Cards*).

Para cada fragmento utilizado na resposta, o sistema exibirá um componente expansível contendo:

- **Texto Original:** O parágrafo bruto extraído do PDF;

¹⁶ *Grounding* (Ancoragem): Técnica que obriga o modelo a fundamentar suas respostas exclusivamente nos dados fornecidos no contexto, proibindo o uso de conhecimento prévio externo.

¹⁷ *Negative Constraints* (Restrições Negativas): Instruções explícitas que orientam o modelo a **não** responder caso a informação não seja encontrada no contexto, prevenindo a invenção de dados.

- **Score de Confiança:** A pontuação de relevância atribuída pelo *Cohere Reranker* (ex: 0.89), permitindo ao usuário avaliar a certeza do modelo;
- **Link de Proveniência:** Hiperlink direto para a página do documento oficial no portal da universidade.

3.5 Etapa 5: Protocolo de Avaliação e Calibração

A validação do artefato seguirá uma abordagem mista (quantitativa-qualitativa) para garantir robustez estatística e alinhamento semântico.

1. Construção do Dataset de Teste ($N = 100$):

Será compilado um *Golden Dataset* híbrido dividido em dois estratos:

- **Estrato A (Real - 50%):** Perguntas coletadas via formulário junto a discentes e secretários de colegiado da UNIVASF, refletindo a linguagem natural ruidosa e dúvidas reais do cotidiano acadêmico. *Nota de Conformidade:* Este subconjunto será submetido a um processo de sanitização automática e revisão manual para remoção de quaisquer dados pessoais identificáveis (PII), assegurando estrita aderência à Lei Geral de Proteção de Dados (LGPD).
- **Estrato B (Sintético - 50%):** Perguntas geradas via técnica de *Evolution* [Es et al., 2025], onde um LLM reescreve questões simples tornando-as complexas ou condicionais, forçando o sistema a raciocinar sobre múltiplos documentos simultaneamente.

2. Métricas Automatizadas (Juiz Sintético):

O *dataset* será submetido ao *framework* RAGAS utilizando o modelo GPT-4o como juiz. Serão calculadas as métricas de **Fidelidade** (prevenção de alucinação) e **Relevância da Resposta** (utilidade).

3. Calibração Humana:

Para validar a confiabilidade do juiz sintético, aplicar-se-á um protocolo de calibração em uma subamostra aleatória de 30% ($n = 30$). Dois avaliadores humanos (*experts* no domínio) classificarão as respostas cegamente, utilizando uma Escala Likert de 5 pontos (Figura 9).

Posteriormente, será calculado o Coeficiente de Correlação de *Pearson* (r) entre a média das notas humanas e o *score* do RAGAS. O critério de sucesso para validação do método automatizado é estabelecido em $r > 0.7$ (correlação forte).

4 Trabalhos Relacionados e Diferenciação

A aplicação de Grandes Modelos de Linguagem (LLMs) no domínio jurídico tem sido amplamente explorada tanto pela indústria quanto pela academia. Esta seção analisa as abordagens atuais para situar a contribuição específica deste trabalho.

Tabela 1. Diferenciação da proposta frente ao estado da arte nacional e comercial

Dimensão	Estado da Arte (Cabral, 2025)	Proposta Atual (Advanced RAG Jurídico)
Segmentação	Semântica (baseada em modelos ou heurística), sujeita a quebras arbitrárias.	Determinística e Escalável , baseada na estrutura federal da LC 95/1998.
Recuperação	Busca Vetorial + Reranking (Amazon/BGE).	Híbrida (BM25 + Vetor) + Hard Filter de Vigência + Reranking (Cohere).
Segurança Jurídica	Sem tratamento explícito de revogação (risco de alucinação legal).	Controle de Vigência via metadados antes da recuperação.
Avaliação	Métricas de Recuperação (Recall/Precision) e qualitativa.	RAGAS (Fidelidade/Relevância) + Calibração Humana ($r > 0.7$).

Figura 9. Critérios utilizados pelos avaliadores humanos para calibração do juiz sintético.

Rubrica de Avaliação Humana (Escala Likert): 1 - Crítico: A resposta contém alucinação grave ou inventa normas inexistentes. 2 - Ruim: A resposta é vaga, não cita fontes ou erra o contexto da pergunta. 3 - Regular: A resposta está correta, mas incompleta ou cita o artigo errado. 4 - Bom: A resposta está correta e bem fundamentada, com pequenos erros de formatação. 5 - Excelente: A resposta é precisa, completa, cita o artigo correto e o link de vigência funciona.

Fonte: Elaborado pelo autor (2025).

4.1 Soluções Generalistas e Acadêmicas

No cenário comercial, ferramentas como o **Google NotebookLM** exemplificam o estado da arte em RAG generalista. Embora capazes de processar múltiplos PDFs com janelas de contexto longas, essas soluções utilizam estratégias de segmentação agnósticas (*fixed-size chunking*), tratando estatutos como prosa narrativa e ignorando a estrutura lógica da norma [Google, 2024].

No contexto acadêmico nacional, Cabral [2025] desenvolveu na UFRN um *chatbot* para acesso a regulamentos acadêmicos. O trabalho avançou ao implementar etapas de pós-recuperação (*reranking*), demonstrando que a reordenação de resultados é superior à busca vetorial pura para o domínio universitário.

Entretanto, embora Cabral [2025] tenha obtido bons resultados de recuperação, sua abordagem não formalizou um protocolo de **Controle de Vigência**, deixando o sistema suscetível a recuperar normas revogadas que ainda constam nos vetores. Além disso, a segmentação adotada, embora semântica, depende de heurísticas que não garantem a preservação da unidade "Artigo-Parágrafo" em casos complexos, lacunas que o presente trabalho visa preencher.

4.2 Diferenciação e Escalabilidade (A Abordagem LC 95/1998)

Este trabalho avança sobre o estado da arte ao propor uma arquitetura de **RAG Jurídico Estrito**. A principal diferenciação reside no abandono da segmentação probabilística em favor de um *pipeline* determinístico fundamentado na legislação federal.

A adoção da **Lei Complementar n.º 95/1998** [Brasil, 1998] como diretriz de segmentação transcende o

contexto local da UNIVASF. Por se tratar da norma que disciplina a elaboração e redação de leis em todo o Brasil, o algoritmo de *chunking* aqui proposto possui **escalabilidade imediata** para qualquer *corpus* jurídico nacional (Leis Federais, Decretos, Portarias).

Diferente de abordagens que dependem de IA para "adivinhar" onde quebrar o texto, o uso da estrutura canônica da LC 95 (Artigo → Parágrafo → Inciso) confere determinismo e integridade semântica ao vetor. Isso garante que a unidade mínima de recuperação seja sempre um dispositivo legal completo e autocontido, essencial para a segurança jurídica da resposta.

A tabela 1 sumariza os avanços propostos em relação aos trabalhos correlatos.

5 Cronograma de Execução

O desenvolvimento da solução e a escrita da monografia final (TCC II) seguirão o cronograma disposto na Tabela 2, compreendendo o período de janeiro de 2026 a julho de 2026.

As atividades foram planejadas para mitigar riscos de integração, permitindo que o desenvolvimento da interface web (Etapa 4) ocorra em paralelo ao refinamento do *pipeline* de recuperação (Etapa 3), assegurando tempo hábil para a coleta de dados de validação e calibração humana (Etapa 5).

Referências

Brasil (1998). Lei complementar n. 95, de 26 de fevereiro de 1998. *Diário Oficial da União*, page 1. Dispõe sobre a elaboração, a redação, a alteração e a consolidação das leis.

Cabral, J. P. F. (2025). Chatbot inteligente para acesso a regulamentos acadêmicos: Um sistema de recuperação de informações baseado em RAG. Trabalho de conclusão de curso (engenharia de computação), Universidade Federal do Rio Grande do Norte (UFRN), Natal, RN. Orientador: Jean Mario Moreira de Lima.

Cohere (2024). Rerank 3: High performance reranking model. Cohere Blog. Acessado em: 27 nov. 2025.

Dahl, M., Magesh, V., Suzgun, M., and Ho, D. E. (2024). Large legal fictions: Profiling legal hallucinations in large language models. *Journal of Legal Analysis*, 16(1):6493. DOI: 10.1093/jla/laae003.

Es, S., James, J., Espinosa-Anke, L., and Schockaert,

Tabela 2. Cronograma de atividades previsto para o TCC II (2026)

Etapas e Atividades (2026)	Jan	Fev	Mar	Abr	Mai	Jun	Jul
1. Revisão Bibliográfica e Ajustes do Projeto	X	X					
2. Coleta de Dados e Script de ETL (LC 95/98)	X	X					
3. Implementação do Chunking e Indexação		X	X	X			
4. Pipeline RAG (Reranker) e Interface Web			X	X	X		
5. Avaliação (RAGAS) e Calibração Humana					X	X	
6. Análise de Resultados e Escrita Final						X	X
7. Defesa do TCC							X

S. (2025). Ragas: Automated evaluation of retrieval augmented generation.

Gao, Y. *et al.* (2023). Retrieval-augmented generation for large language models: A survey. *arXiv preprint arXiv:2312.10997*. DOI: 10.48550/arXiv.2312.10997.

Google (2024). Notebooklm: Ai-first notebook for research. Acessado em: 27 nov. 2025.

Grand View Research (2024). Brazil chatbot market size, share & trends analysis report (2024-2030). Acessado em: 26 nov. 2025.

Guha, N., Nyarko, J., Ho, D. E., Ré, C., Chilton, A., Narayana, A., Chohlas-Wood, A., Peters, A., Waldon, B., Rockmore, D. N., Zambrano, D., Talisman, D., Hoque, E., Surani, F., Fagan, F., Sarfaty, G., Dickinson, G. M., Porat, H., Hegland, J., Wu, J., Nudell, J., Niklaus, J., Nay, J., Choi, J. H., Tobia, K., Hagan, M., Ma, M., Livermore, M., Rasumov-Rahe, N., Holzenberger, N., Kolt, N., Henderson, P., Rehaag, S., Goel, S., Gao, S., Williams, S., Gandhi, S., Zur, T., Iyer, V., and Li, Z. (2023). Legalbench: A collaboratively built benchmark for measuring legal reasoning in large language models.

IBM Research (2024). Docling: The document conversion library. GitHub Repository. Acessado em: 28 nov. 2025.

INEP and Ministério da Educação (2025). Censo da educação superior 2024: Divulgação dos resultados. Relatório Técnico. Acessado em: 26 nov. 2025.

Ji, Z., Lee, N., Frieske, R., Yu, T., Su, D., Xu, Y., Ishii, E., Bang, Y. J., Madotto, A., and Fung, P. (2023). Survey of hallucination in natural language generation. *ACM Comput. Surv.*, 55(12). DOI: 10.1145/3571730.

Lewis, P., Perez, E., Piktus, A., Petroni, F., *et al.* (2021). Retrieval-augmented generation for knowledge-intensive nlp tasks. In *Advances in Neural Information Processing Systems (NeurIPS)*, volume 33, pages 9459–9474. DOI: 10.48550/arXiv.2005.11401.

Li, H., Dong, Q., Chen, J., Su, H., Zhou, Y., Ai, Q., Ye, Z., and Liu, Y. (2024). Llms-as-judges: A comprehensive survey on llm-based evaluation methods.

Liu, N. F., Lin, K., Hewitt, J., Paranjape, A., Bevilacqua, M., Petroni, F., and Liang, P. (2024). Lost in the middle: How language models use long contexts. *Transactions of the Association for Computational Linguistics*, 12:157–173. DOI: 10.1162/tacl_a_00638.

Mobile Time and Opinion Box (2024). Pesquisa panorama mobile time: Mapa do ecossistema brasileiro de bots. Relatório Técnico. Acessado em: 26 nov. 2025.

Muhammed, A. (2025). Ccrs: A zero-shot llm-as-a-judge framework for comprehensive rag evaluation.

OpenAI (2024a). Openai platform documentation: Embeddings. Documentation. Acessado em: 27 nov. 2025.

OpenAI (2024b). Prompt engineering guide. Documentation. Acessado em: 27 nov. 2025.

Reimers, N. and Gurevych, I. (2019). Sentence-bert: Sentence embeddings using siamese bert-networks.

Saccaro, A., França, M. T. A., and Jacinto, P. d. A. (2019). Fatores associados à evasão no ensino superior brasileiro: um estudo de análise de sobrevivência. *Estudos Econômicos (São Paulo)*, 49(2):337–373. DOI: 10.1590/0101-41614925amp.

Santos, C. A. d., Pereira, G. d. Q., and Pilatti, L. A. (2025). Análise dos fatores determinantes da evasão no ensino superior brasileiro e propostas de mitigação. *Revista on line de Política e Gestão Educacional*, 29:e025014. DOI: 10.22633/rpge.v29i00.20180.

Seenivasan, D. (2023). ETL (Extract, Transform, Load) best practices. *International Journal of Computer Trends and Technology*, 71(1):40–44. DOI: 10.14445/22312803/IJCTT-V71I1P106.